范谢逸 (Ivan)

AI/Agent & 全栈工程师

杭州, 中国 | blues74285700@gmail.com | +86 152 5716 4640 | +852 8403 0728 | IvanFan-Van

教育背景

香港大学, BEng (2023.09 - 2027.06) in 计算机工程

- 2023 Dean's Honour List

技能

编程语言: Python, TypeScript, Java, Cpp/C, PHP, SQL

AI/Agent: LangGraph/LangChain, PyTorch(CNN, RNN, LSTM, Transformer, VAE, VLA), pandas, scikit-learn, SciPy

强化学习: DQN, DQN Variants, GRPO, PPO, SAC

全栈: FastAPI, express.js, Node.js, React, React Router, Tailwind CSS, Vite, Shadcn/ui, SQLite, MySQL, PostgreSQL, MongoDB

2023

全栈开发工程师, **TripleUni**

为 TripleUni 三校树洞平台（注册用户超 20,000 人）独立开发服务健康监控系统。旨在提供一个统一的检查和管理多服务健康状态以便于快速修复异常的平台. 使用 apschedule, fastapi, sqlite 构建该项目

- 监控平台：搭建主动健康监控平台，HTTP/WebSocket/SSE 探针覆盖 12+ 项核心服务；服务异常时通过飞书实时告警，服务状态与日志随时可见——将 bug 发现时间从最长 72 小时（依赖用户反馈）缩短至分钟级（探针频率：读接口 1 分钟，写接口 1 小时）
- 架构改进：主导后端重构，建立独立测试服务器并标准化 CI/CD 流程，杜绝直接生产部署及相关事故

2024

全栈开发工程师, **HKU Innovation Wing** 实验室

利用香港大学图书馆的历史档案资料，为香港文化遗产构建一个人工智能系统。使用 MinerU 和 VLM 构建双语 pdf 预处理管道, 并使用 Langchain 构建 RAG 工作流

- 针对 MinerU 开源工具无法识别正文段落中图像描述、影响多模态检索 caption 的问题，收集图像邻域及同页前后 3–5 个文本块、跨页候选，结合指代/图注关键词、文本-图像距离向量、无语义图注 ID 筛选候选，多候选时 VLM 精排，无候选时嵌入图像链接至页尾兜底；最终图片匹配准确率从 40% 提升至 100%。
- 集成 Agent 网络检索并设计多源数据过滤机制：针对百度百科、维基百科、民间博客等低权威来源导致的信息不对症与幻觉风险，建立权威历史数据网站白名单，将检索范围收敛至可信历史数据源，消除非权威信息干扰，提升 RAG 回复精确度与可信度.

2025

全栈开发工程师, **HKU Innovation Wing** 实验室

与香港大学 UMAG 博物馆合作开发的智能导游系统，旨在应对图书馆讲解员短缺的问题。该应用提供了实时语音交互以及多模态信息检索功能，帮助用户更好地了解馆藏文物。(LangGraph, ONNX, Agentic RAG)

- 针对中英双语图文文档经 MinerU 解析后出现的中英文混杂、caption 误插正文等错乱问题，设计基于中英文占比与特定定规则正则表达式实现的语言分离程序，结合 Sentence Transformer 句子顺序似然（P(A,B)>P(B,A) 判定合理顺序）重排句子，并利用欧几里得距离判定文本与图像邻近关系以校正 caption 位置，有效提升文档解析质量。
- 设计并实现 Reflection-RAG 反思机制，应对高精度历史介绍场景中人名、地名、时间等易被模型幻觉伪造的问题：生成后由反思节点评估回复是否解决用户 query、是否包含未基于文档给定信息的幻觉；Correct 直接返回，Incorrect 则附加 feedback（未响应部分、幻觉部分）交由 Generator 重新生成；若因文档信息缺失无法完整响应，则触发 Web Search 从互联网检索补充，提升回复准确性与完整性。
- 针对多轮 RAG 对话中 “similar artifact” 等指代词/模糊表述导致关键词检索失效的问题，引入 Query Rewriter 机制，将指代与模糊词汇改写为上一轮对话中的具体实体，提升检索查询的明确性与关键词召回效果。
- 针对游客泛化提问（如“介绍一下这个 artifact”）难以命中制作工艺、历史背景、文化意义等深层信息的问题，设计 Query Decomposition + Enhancement 检索优化机制：先将原始 query 分解为多个 sub query 提升问题的丰富性, 紧接着再对每个 sub query 使用 Q2D 生成伪回复并与原始 query 拼接，以引入更多上下文、提升关键词匹配与相关文档召回；同时保留原始 query 共同检索以抑制伪文档幻觉，最终提升泛化 query 下的信息覆盖度与检索相关性。
- 多模态检索：基于 Dino 构建图像向量检索引擎，实现拍照即搜文物；
- 自建 1K 评估数据集，验证 hybrid search（keyword + semantic + sparse）最优组合；
- 基于 ONNX 技术在端侧部署 TTS 与 ASR 模型，将请求到首次 TTS 播放的延迟降低 50%

全栈开发工程师, **HKU Med IT Department – Research Data Collaboration Catalogue**

构建香港大学医学院内部研究协作平台，用于促进 200 余位教授之间的跨学科合作。(Next.js · FastAPI · PubMed API)

- 清洗并标准化了 200 余位教授 的个人资料、研究成果及合作数据，并使用 Next.js 构建完整应用
- 作者姓名消歧：利用官网额外信息、姓名归一化与 fuzzy search，解决中英文姓名变体及跨论文/期刊署名不一致问题
- 论文去重：基于 SimHash + 元数据匹配对多来源论文去重；设计医学关键词搜索引擎（词干提取、模糊匹配、多维筛选），集成 PubMed API 自动抓取论文

2026

研究助理 **(具身智能)**, 香港大学 – **Prof. YanChao Yang** 研究团队

研究如何引入多模态数据 (EEG, EMG, eye gaze) 来增强 VLA 模型性能。(Pytorch, ALOHA, EEG/EMG)

- 提出一种仅训练阶段融合多模态数据、推理阶段无需多模态输入对的 VLA 增强方法：采集 EEG、EMG、Eye Gaze 三种额外模态，在 OpenVLA 模型架构内嵌两个生成器模块模拟大脑 EEG/EMG 信号，在训练时通过 KL 散度对齐生成器分布与真实数据分布；将 Eye Gaze 分布用于 Attention 最后一层、Action 层前的归一化，在不增加推理阶段多模态配对依赖的前提下增强 VLA 能力。

开源项目贡献

urdf-visualizer (219 GitHub stars)

- 修复了 xacro 语法兼容性问题，使插件能够正确解析 xacro 格式的 URDF 文件。

竞赛

字节跳动 **AI** 全栈挑战赛 – 爆款视频风格迁移赛道（**12** 赛道之一）

- 构建 Agent 系统分析爆款视频特征，结合 Remotion 框架自动生成视频剪辑。获得直通面试资格